



INSTITUTO FEDERAL DO PIAUÍ – CAMPUS CORRENTE

Aluna: Klesly de Souza Rocha/ ADS – MOD. III

Professor: Msc. Igor Bezerra Reis

Disciplina: Inteligência Artificial

Deteccção de Objetos Cotidianos Utilizando o Modelo YOLOv8 e o Dataset COCO

Resumo

A detecção de objetos constitui uma das principais aplicações da Visão Computacional, sendo empregada em diversas áreas, como segurança eletrônica, veículos autônomos, monitoramento urbano, automação industrial e robótica. Entre os modelos mais utilizados para essa finalidade destaca-se o YOLO (You Only Look Once), reconhecido por apresentar elevado desempenho aliado à capacidade de processamento em tempo real. Neste trabalho foi desenvolvido um sistema de detecção de objetos utilizando o modelo YOLOv8, implementado na linguagem Python por meio da biblioteca Ultralytics e executado na plataforma Google Colab. Como base para os experimentos foi utilizado o dataset COCO, em sua versão reduzida COCO128, contendo imagens anotadas com diferentes categorias de objetos. Durante o desenvolvimento foram realizados experimentos alterando o limiar de confiança (*Confidence Threshold*) e o limiar de *Intersection over Union* (IoU) empregado pelo algoritmo *Non-Maximum Suppression* (NMS), permitindo avaliar como essas configurações influenciam o desempenho do modelo. A análise foi realizada utilizando as métricas $mAP@0.5$, $mAP@0.5:0.95$, Precisão, Recall, F1-score e *Frames per Second* (FPS). Os resultados obtidos demonstraram que o YOLOv8 apresenta excelente equilíbrio entre velocidade de processamento e qualidade das detecções, confirmando sua eficiência para aplicações de detecção de múltiplos objetos em tempo real.

Palavras-chave: Inteligência Artificial; Visão Computacional; YOLOv8; COCO; Detecção de Objetos.

Abstract

Object detection is one of the main applications of Computer Vision and has been widely used in areas such as electronic surveillance, autonomous vehicles, industrial automation, robotics and smart cities. Among the existing object detection models, YOLO (You Only Look Once) stands out due to its high accuracy combined with real-time processing capability. This paper presents the development of an object detection system using the YOLOv8 model, implemented in Python with the Ultralytics library and executed on the Google Colab platform. The COCO dataset, specifically its reduced version COCO128, was used to evaluate the proposed approach. Experiments were performed by varying the Confidence Threshold and the Intersection over Union (IoU) threshold applied by the Non-Maximum Suppression (NMS) algorithm. The evaluation considered the metrics $mAP@0.5$, $mAP@0.5:0.95$, Precision, Recall, F1-score and Frames per Second (FPS). The results indicate that YOLOv8 provides an excellent balance between detection accuracy and computational performance, making it suitable for real-time object detection applications.

Keywords: Artificial Intelligence; Computer Vision; YOLOv8; COCO; Object Detection.

1. Introdução

A evolução da Inteligência Artificial (IA) tem impulsionado o desenvolvimento de sistemas capazes de interpretar grandes volumes de dados e auxiliar na tomada de decisões em diferentes áreas do conhecimento. Dentro desse contexto, a Visão Computacional tornou-se um dos campos de pesquisa mais relevantes, permitindo que computadores interpretem imagens e vídeos de maneira semelhante à percepção humana. Essa tecnologia vem sendo aplicada em sistemas de monitoramento, diagnóstico médico, agricultura de precisão, inspeção industrial, veículos autônomos e diversas outras aplicações que dependem da identificação automática de objetos.

A detecção de objetos consiste em localizar e identificar diferentes elementos presentes em uma imagem, atribuindo a cada um deles uma classe e uma posição por meio de caixas delimitadoras (*Bounding Boxes*). Diferentemente da classificação de imagens, em que apenas uma categoria é atribuída à imagem inteira, a detecção permite reconhecer simultaneamente vários objetos pertencentes a diferentes classes.

Nos últimos anos, diversos modelos baseados em redes neurais convolucionais foram desenvolvidos para resolver esse problema. Entre eles destaca-se a família YOLO (*You Only Look Once*), conhecida por realizar a localização e a classificação dos objetos em uma única etapa de processamento. Essa característica proporciona elevado desempenho computacional e baixa latência, tornando o modelo adequado para aplicações em tempo real.

A versão mais recente dessa família, o YOLOv8, apresenta melhorias significativas em relação às versões anteriores, oferecendo maior precisão, melhor capacidade de generalização e facilidade de implementação por meio da biblioteca Ultralytics. Essas características tornam o modelo uma alternativa eficiente tanto para aplicações acadêmicas quanto para soluções comerciais.

Neste trabalho foi desenvolvido um sistema de detecção de objetos utilizando o modelo YOLOv8 sobre o dataset COCO, empregando a plataforma Google Colab como ambiente de desenvolvimento. Foram realizados experimentos variando o limiar de confiança (*Confidence Threshold*) e o limiar de *Intersection over Union* (IoU) utilizado pelo algoritmo *Non-Maximum Suppression* (NMS), buscando analisar a influência desses parâmetros sobre a qualidade das detecções e o desempenho computacional do modelo. Para essa avaliação foram utilizadas as métricas mAP@0.5, mAP@0.5:0.95, Precisão, Recall, F1-score e *Frames per Second* (FPS).

Além de apresentar os resultados experimentais, este trabalho busca demonstrar a importância da escolha adequada dos parâmetros do modelo, evidenciando o equilíbrio existente entre precisão e velocidade, aspecto fundamental em aplicações de detecção de objetos em tempo real.

2. Fundamentação Teórica

2.1 Inteligência Artificial e Visão Computacional

A Inteligência Artificial (IA) é uma área da Ciência da Computação dedicada ao desenvolvimento de sistemas capazes de executar tarefas que normalmente exigiriam inteligência humana, como reconhecimento de padrões, tomada de decisão, aprendizado e resolução de problemas. O avanço da capacidade computacional e o aumento da disponibilidade de dados contribuíram significativamente para a evolução dessa área, permitindo o desenvolvimento de algoritmos cada vez mais eficientes em diferentes aplicações.

Entre os diversos ramos da Inteligência Artificial destaca-se a Visão Computacional, responsável por permitir que computadores interpretem informações obtidas por meio de imagens e vídeos. Seu principal objetivo é extrair conhecimento relevante do ambiente visual, identificando objetos, pessoas, cenários e eventos de forma automática.

Nos últimos anos, a Visão Computacional tornou-se fundamental em aplicações como sistemas de vigilância, reconhecimento facial, inspeção industrial, veículos autônomos, agricultura de precisão e diagnóstico por imagens. Em todas essas aplicações, a capacidade de detectar corretamente diferentes objetos influencia diretamente a qualidade dos resultados obtidos.

O avanço das técnicas de Aprendizado Profundo (*Deep Learning*) revolucionou essa área ao possibilitar que redes neurais aprendam automaticamente características relevantes das imagens, dispensando a necessidade de extração manual de atributos. Dessa forma, modelos modernos conseguem apresentar elevado desempenho mesmo em cenários complexos e com grande quantidade de objetos simultaneamente.

2.2 O Modelo YOLOv8

O YOLO (*You Only Look Once*) é uma família de modelos de detecção de objetos baseada em redes neurais convolucionais (*Convolutional Neural Networks* – *CNNs*). Seu principal diferencial está na capacidade de localizar e classificar múltiplos objetos presentes em uma imagem por meio de uma única passagem pela rede neural, reduzindo significativamente o tempo de processamento quando comparado a métodos tradicionais.

A versão YOLOv8 representa uma evolução dessa arquitetura, incorporando melhorias relacionadas à extração de características, eficiência computacional e capacidade de generalização. Desenvolvido pela Ultralytics, o modelo apresenta uma implementação simplificada que facilita tanto o treinamento quanto a validação e a inferência de modelos de detecção de objetos.

A arquitetura do YOLOv8 pode ser dividida em três componentes principais:

- **Backbone:** responsável pela extração das características da imagem, identificando padrões como bordas, formas, texturas e estruturas relevantes para a detecção dos objetos.
- **Neck:** realiza a integração das informações extraídas em diferentes níveis da rede, permitindo que objetos de diferentes tamanhos sejam identificados com maior eficiência.
- **Head:** executa a etapa final da detecção, produzindo as caixas delimitadoras (*Bounding Boxes*), classificando cada objeto detectado e atribuindo um nível de confiança para cada previsão realizada.

Essa arquitetura permite que o modelo realize a detecção de múltiplos objetos com elevada velocidade, tornando-o apropriado para aplicações que exigem processamento em tempo real.

2.3 Dataset COCO

O *Common Objects in Context* (COCO) é um dos conjuntos de dados mais utilizados no desenvolvimento e avaliação de algoritmos de Visão Computacional. Criado com o objetivo de representar situações do cotidiano, o dataset reúne milhares de imagens contendo múltiplos objetos pertencentes a diferentes categorias.

Cada imagem do COCO possui anotações detalhadas, incluindo a localização dos objetos por meio de caixas delimitadoras, segmentações e informações referentes às classes presentes. Essas características tornam o dataset uma importante referência para avaliação de modelos de detecção de objetos.

Neste trabalho foi utilizada a versão COCO128, uma versão reduzida do COCO oficial disponibilizada pela Ultralytics para testes rápidos e experimentação. Embora contenha apenas 128 imagens, essa versão preserva a estrutura de organização do dataset original, possibilitando a utilização das mesmas ferramentas de avaliação empregadas no COCO completo.

As classes presentes no COCO incluem pessoas, automóveis, bicicletas, motocicletas, ônibus, caminhões, cadeiras, mochilas, televisores, notebooks, garrafas, celulares, animais e diversos outros objetos encontrados em ambientes cotidianos.

2.4 Confidence Threshold

Durante a execução do modelo, cada objeto detectado recebe um valor de confiança que representa a probabilidade de aquela detecção estar correta. Esse valor é conhecido como Confidence Score.

O Confidence Threshold define o valor mínimo necessário para que uma detecção seja aceita pelo algoritmo. Quando esse limiar é configurado com valores reduzidos, o modelo tende a detectar um número maior de objetos, aumentando também a probabilidade de falsos positivos.

Por outro lado, valores elevados tornam o modelo mais rigoroso, aceitando apenas detecções com alta confiabilidade. Essa configuração normalmente aumenta a precisão das previsões, porém pode reduzir o número de objetos corretamente identificados, diminuindo o Recall.

A escolha adequada desse parâmetro depende do tipo de aplicação e do equilíbrio desejado entre quantidade de detecções e confiabilidade dos resultados.

2.5 Intersection over Union (IoU)

O *Intersection over Union* (IoU) é uma métrica utilizada para medir o grau de sobreposição entre duas caixas delimitadoras. No contexto da detecção de objetos, essa métrica compara a caixa prevista pelo modelo com a anotação considerada correta (*Ground Truth*).

Seu cálculo é realizado dividindo a área de interseção entre as duas caixas pela área correspondente à união dessas regiões. Quanto maior o valor obtido, maior será a correspondência entre a previsão realizada pelo modelo e a posição real do objeto.

Além de ser empregado na avaliação do desempenho do algoritmo, o IoU também desempenha papel fundamental no funcionamento do algoritmo *Non-Maximum Suppression*.

2.6 Non-Maximum Suppression (NMS)

Durante a detecção de objetos é comum que o modelo gere diversas caixas delimitadoras para representar um mesmo objeto. Essas caixas normalmente apresentam diferentes níveis de confiança e elevado grau de sobreposição.

Para eliminar essas duplicidades utiliza-se o algoritmo Non-Maximum Suppression (NMS). Inicialmente, o algoritmo seleciona a caixa que apresenta o maior nível de confiança. Em seguida, todas as demais caixas cuja sobreposição ultrapassa o limiar de IoU definido são descartadas. Esse processo é repetido até que permaneçam apenas as detecções mais representativas.

A utilização do NMS reduz significativamente a ocorrência de múltiplas detecções para um mesmo objeto, melhorando a qualidade das previsões produzidas pelo modelo.

3. Metodologia

Este trabalho caracteriza-se como uma pesquisa aplicada de natureza experimental, cujo objetivo foi analisar o desempenho do modelo YOLOv8 na detecção de objetos cotidianos utilizando diferentes configurações dos parâmetros de inferência. A metodologia adotada envolveu a utilização de um modelo pré-treinado, a execução de experimentos controlados e a análise das métricas geradas durante o processo de validação.

O ambiente de desenvolvimento utilizado foi o Google Colab, plataforma baseada em computação em nuvem que oferece suporte à linguagem Python e permite a utilização de recursos computacionais para aplicações de Inteligência Artificial. A escolha dessa plataforma ocorreu devido à facilidade de configuração do ambiente, disponibilidade de bibliotecas atualizadas e acesso a recursos de processamento sem necessidade de instalação local.

A implementação foi realizada utilizando a linguagem Python, amplamente empregada em projetos de Aprendizado de Máquina e Visão Computacional. Para a execução do modelo foi utilizada a biblioteca Ultralytics, responsável por disponibilizar a implementação oficial do YOLOv8, incluindo funcionalidades para carregamento de modelos pré-treinados, inferência, validação e avaliação de desempenho.

O modelo escolhido para os experimentos foi o YOLOv8 Nano (yolov8n.pt). Essa versão apresenta arquitetura compacta, reduzido consumo de memória e elevada velocidade de processamento, características que a tornam adequada para experimentos acadêmicos e aplicações em tempo real. Além disso, o modelo já se encontra previamente treinado sobre o dataset COCO, permitindo sua utilização sem necessidade de um processo adicional de treinamento.

Como conjunto de dados foi utilizada a versão COCO128, disponibilizada pela Ultralytics. Esse conjunto corresponde a uma versão reduzida do dataset COCO original e contém imagens anotadas pertencentes a aproximadamente 80 categorias de objetos. Apesar do número reduzido de imagens, sua estrutura é compatível com a utilizada pelo dataset completo, possibilitando a realização de experimentos de validação de maneira mais rápida e eficiente.

Inicialmente foi realizada a instalação das bibliotecas necessárias para execução do projeto, incluindo a biblioteca Ultralytics. Em seguida, efetuou-se o download do conjunto de dados COCO128 e o carregamento do modelo YOLOv8 Nano previamente treinado. Após essa etapa, foram realizados testes de inferência em imagens pertencentes ao conjunto de dados, permitindo verificar o funcionamento do algoritmo e visualizar as caixas delimitadoras correspondentes aos objetos detectados.

Além da visualização das detecções, também foram apresentadas as classes identificadas pelo modelo e seus respectivos níveis de confiança. Essa etapa possibilitou confirmar que o algoritmo foi capaz de reconhecer corretamente diferentes objetos presentes nas imagens avaliadas, demonstrando o funcionamento adequado do sistema desenvolvido.

Para atender aos objetivos propostos, foram conduzidos três experimentos variando os parâmetros Confidence Threshold e Intersection over Union (IoU) utilizados durante o processo de inferência. O primeiro experimento utilizou *Confidence* igual a 0,25 e *IoU* igual a 0,45, configuração recomendada como padrão pela biblioteca Ultralytics. O segundo experimento aumentou o limiar de confiança para 0,50, mantendo o mesmo valor de IoU. Por fim, o terceiro experimento utilizou *Confidence* igual a 0,50 e aumentou o limiar de IoU para 0,70, permitindo avaliar o comportamento do algoritmo *Non-Maximum Suppression* sob uma configuração mais restritiva.

A Tabela 1 apresenta as configurações utilizadas durante os experimentos.

Tabela 1 – Configurações experimentais utilizadas

Experimento	Confidence	IoU
Experimento 1	0,25	,45
Experimento 2	0,50	,45
Experimento 3	0,50	,70

Após a execução de cada experimento, o desempenho do modelo foi avaliado por meio das métricas disponibilizadas pela biblioteca Ultralytics. Foram consideradas as métricas mAP@0.5, mAP@0.5:0.95, Precisão, Recall, F1-score e Frames por Segundo (FPS), permitindo uma análise abrangente tanto da qualidade das detecções quanto do desempenho computacional do algoritmo.

O mAP@0.5 foi utilizado para avaliar a capacidade do modelo em localizar corretamente os objetos considerando um limiar de IoU igual a 0,5. Já o mAP@0.5:0.95 forneceu uma avaliação mais rigorosa ao considerar múltiplos limiares de IoU, permitindo medir a robustez do modelo em diferentes níveis de exigência.

As métricas de Precisão e Recall possibilitaram analisar, respectivamente, a proporção de detecções corretas realizadas pelo modelo e sua capacidade de identificar todos os objetos existentes nas imagens avaliadas. O F1-score foi calculado para representar o equilíbrio entre essas duas métricas, enquanto o FPS foi empregado para medir a velocidade de processamento alcançada durante os experimentos.

A combinação dessas métricas permitiu avaliar de forma objetiva o impacto das diferentes configurações de *Confidence Threshold* e *IoU* sobre o desempenho do YOLOv8, possibilitando identificar a configuração que apresentou o melhor equilíbrio entre precisão das detecções e velocidade de execução.

4. Resultados e Discussão

Após a implementação do sistema de detecção de objetos utilizando o modelo YOLOv8, foram realizados experimentos com diferentes configurações dos parâmetros Confidence Threshold e Intersection over Union (IoU). O objetivo foi analisar como essas configurações influenciam a capacidade do modelo em identificar corretamente os objetos presentes nas imagens, bem como seu desempenho computacional.

Inicialmente, foi realizada uma inferência sobre imagens pertencentes ao dataset COCO128. O modelo identificou corretamente diferentes categorias de objetos, como pessoas, veículos, cadeiras, mochilas, bicicletas e outros elementos presentes nas cenas. Cada objeto detectado foi representado por uma caixa delimitadora (*Bounding Box*), acompanhada da classe prevista e do respectivo nível de confiança.

A Figura 1 apresenta um exemplo de detecção realizada pelo sistema desenvolvido.




Figura 1 – Exemplo de detecção de objetos utilizando o YOLOv8 sobre uma imagem do dataset COCO128.

A análise visual permitiu verificar que o modelo foi capaz de localizar corretamente múltiplos objetos presentes na mesma imagem, demonstrando sua eficiência na tarefa de detecção em cenários cotidianos.

Posteriormente, foram executados três experimentos utilizando diferentes combinações dos parâmetros de confiança e IoU. A primeira configuração empregou Confidence = 0,25 e IoU = 0,45, correspondendo aos valores recomendados pela biblioteca Ultralytics para aplicações gerais. Essa configuração apresentou maior sensibilidade na identificação dos objetos, detectando uma quantidade mais elevada de elementos presentes nas imagens. Entretanto, observou-se que algumas detecções apresentavam níveis de confiança reduzidos, aumentando a possibilidade de falsos positivos.

No segundo experimento, o limiar de confiança foi elevado para 0,50, mantendo-se o IoU em 0,45. Nessa configuração, o modelo tornou-se mais rigoroso na aceitação das detecções, reduzindo significativamente a ocorrência de previsões com baixa confiabilidade. Como consequência, houve um aumento na precisão das detecções, embora alguns objetos menos evidentes deixassem de ser identificados.

O terceiro experimento manteve o limiar de confiança em 0,50, porém aumentou o valor do IoU para 0,70. Essa alteração influenciou diretamente o funcionamento do algoritmo *Non-Maximum Suppression*, tornando mais criteriosa a eliminação de caixas delimitadoras sobrepostas. Como resultado, observou-se uma redução na quantidade de caixas duplicadas para um mesmo objeto, contribuindo para uma representação visual mais organizada das detecções.

A Tabela 2 apresenta os resultados obtidos durante a execução dos experimentos.

Tabela 2 – Resultados experimentais obtidos com diferentes configurações de Confidence e IoU

Experimento	Confidence	IoU	mAP@0.5	mAP@0.5:0.95	Precisão	Recall	F1-score	FPS
Exp. 1	0,25	0,45	0.466	0,362	0,714	0,493	0,583	3,428
Exp. 2	0,50	0,45	0,345	0,285	0,768	0,352	0,483	3,519

Experimento	Confidence	IoU	mAP@0.5	mAP@0.5:0.95	Precisão	Recall	F1-score	FPS
Exp. 3	0,50	0,70	0,346	0,287	0,752	0,354	0,481	3,630

Gráfico do **mAP@0.5**




Figura 2 - Esse gráfico mostra qual experimento obteve melhor desempenho.

Gráfico do **Recall**




Figura 3 - Mostra qual configuração conseguiu detectar mais objetos.

Gráfico da **Precisão**




Figura 4 - Mostra qual configuração produziu menos falsos positivos.

Gráfico do FPS




Figura 5 - Mostra a velocidade do modelo.

A métrica $mAP@0.5$ permitiu avaliar a capacidade do modelo em localizar corretamente os objetos considerando um limiar fixo de IoU igual a 0,5. Já o $mAP@0.5:0.95$ forneceu uma avaliação mais rigorosa, utilizando múltiplos limiares de IoU e permitindo uma análise mais abrangente da qualidade das detecções.

As métricas de Precisão e Recall evidenciaram o comportamento esperado em relação às configurações testadas. O aumento do limiar de confiança reduziu a quantidade de falsos positivos, favorecendo a precisão das detecções. Em contrapartida, algumas detecções deixaram de ser realizadas, ocasionando uma redução no Recall. O F1-score permitiu analisar o equilíbrio entre essas duas métricas, indicando a configuração que apresentou melhor compromisso entre identificar corretamente os objetos e minimizar erros de classificação.

O desempenho computacional foi avaliado por meio da métrica Frames por Segundo (FPS). Os resultados demonstraram que o modelo YOLOv8 Nano manteve elevada velocidade de processamento em todas as configurações analisadas, característica que o torna adequado para aplicações em tempo real. Mesmo com alterações nos parâmetros de confiança e IoU, a velocidade de execução apresentou pequenas variações, evidenciando a eficiência computacional do modelo.

De maneira geral, os experimentos demonstraram que a escolha adequada dos parâmetros influencia diretamente o comportamento do algoritmo. Configurações mais permissivas favorecem a identificação de um

número maior de objetos, enquanto configurações mais restritivas aumentam a confiabilidade das detecções. Dessa forma, a definição dos valores de *Confidence Threshold* e *IoU* deve considerar os requisitos específicos de cada aplicação, buscando um equilíbrio entre precisão, capacidade de detecção e desempenho computacional.

5. Referências

KAGGLE. COCO Dataset. Disponível em: <<https://www.kaggle.com/datasets/salargamer/coco-dataset>>.
<https://www.kaggle.com/code/shazminnasir/object-detection-using-yolov8-on-coco-dataset>
<https://iaexpert.academy/2020/10/13/deteccao-de-objetos-com-yolo-uma-abordagem-moderna/>